

ML Principles: labo 1

Hassan Haddouchi

In dit opleidingsonderdeel zullen we een aantal labo's in Python uitvoeren.

Deze opdracht bestaat uit 2 delen. In het eerste deel krijg je voorbeeldcode te zien.

Deel 1

BELANGRIJK: hieronder staat de opdracht maar dit is tegelijkertijd een voorbeeldoplossing van het eerste deel van dit labo. In het eerste deel is het de bedoeling om gelijkaardige stappen uit te voeren, maar dan op een andere dataset.

Gebruik een IDE om lokaal simultaan in meerdere programmeertalen te ontwikkelen.

1. Installeer de volgende software:

- Python: voor de labo's die we in Python zullen uitvoeren
- Visual Studio Code

Labo 1 zal worden uitgevoerd in Python en Visual Studio Code.

2. Maak in Visual Studio Code een nieuw Python bestand aan.

3. Op deze website staan veel datasets: <https://vincentarelbundock.github.io/Rdatasets/datasets.html>
Hieronder voer ik stappen uit op een dataset. De bedoeling van dit labo is om dezelfde stappen uit te voeren, **weliswaar op een ANDERE dataset naar keuze**.

4. Download de dataset en importeer deze. Probeer tijdens de uitvoering van labo's de volgende regels te respecteren:

- Maak gebruik van de nodige Python libraries zoals Pandas om de dataset in te laden en matplotlib om tabellen en grafieken van je dataset te laten weergeven.
- **BELANGRIJK!!! Dit geldt voor alle labo's: maak je code reproduceerbaar en zonder afhankelijkheden (i.e. ik moet de code rechtstreeks kunnen uitvoeren zonder extra bestanden te moeten downloaden, installeren van nieuwe pakketten is wel OK, het pad naar je dataset in dezelfde folder moet werken en je dataset moet je mee indienen).**

5. Voer nu de volgende stappen uit op je dataset:

- Schrijf code om een samenvatting van je dataset te tonen
- Schrijf code om de verdeling van één van de variabelen van je dataset te tonen.

7. Steek je werkende oplossing (Python bestand en de bijhorende dataset) in een .zip bestand en dien dit in op Digitap.

Succes!

Gasoline

In dit voorbeeld werk ik rond dieselprijzen. In deze [oefendatasets](#) vinden we de dataset **OECDGas**. Om deze dataset te gebruiken zal ik het .csv bestand downloaden, in dezelfde map steken als mijn code en vervolgens de dataset in onze code laden.

```
import pandas as pd
import os
import matplotlib.pyplot as plt

print("Current working directory:", os.getcwd())
os.chdir(r'PAD NAAR HUIDIGE FOLDER')
print(os.getcwd())

# Gegevens inladen (ga ervan uit dat 'OECDGas.csv' het CSV-bestand is)
OECDGas = pd.read_csv('OECDGas.csv')

# Converteer naar een pandas DataFrame (optioneel als het al een DataFrame is)
OECDGas = pd.DataFrame(OECDGas)

# Toon een overzicht van de dataset
summary = OECDGas.describe()

# Toon de samenvatting
print(summary)

# Sorteer de dataset op jaar
OECDGas = OECDGas.sort_values(by='year')

# Bereken het gemiddelde van de prijs gegroepeerd op jaar
mean_prices = OECDGas.groupby('year')['price'].mean()

# Maak een lijndiagram van de gemiddelde prijzen per jaar
plt.plot(mean_prices.index, mean_prices.values, marker='o', linestyle='-')
plt.xlabel('Year')
plt.ylabel('Mean Price')
plt.title('Mean Gas Prices Over the Years')
plt.grid(True)
plt.show()
```

Deel 2

In deel 2 zal je iets dieper ingaan op de mogelijke functies die Python voorziet om een dataset te bekijken en inzichten te verwerven.

Maak gebruik van de OECDGas dataset.

Statistieken per categorie:

- Identificeer de variabele prijs in de OECDGas dataset.
- Bereken en toon de gemiddelde, minimale en maximale waarden per categorie in een overzichtelijke tabel.

- Je kan hiervoor gebruikmaken van de volgende functies in pandas: `groupby()`, `agg()` en `pivot_table()` in pandas.

Boxplot van prijzen per categorie

- Maak een boxplot van de gasprijzen voor elke categorie.
- Voeg labels en een titel toe aan het plot.
- Analyseer de boxplot en identificeer eventuele uitschieters.

Tijdreeksanalyse

- Converteer de 'year'-kolom naar een datetimeformaat (gebruik de functie `pd.to_datetime()`).
- Maak een tijdreeksplot van de gasprijzen over de jaren.

Distributie van jaarlijkse veranderingen:

- Bereken de jaarlijkse veranderingen in gasprijzen (gebruik de functie `diff()`).
- Maak een histogram van deze jaarlijkse veranderingen.

Statistieken van specifieke jaarbereiken:

- Selecteer een specifiek jaar- of periodebereik (bijvoorbeeld 2010-2015).
- Bereken statistieken (gemiddelde, standaarddeviatie, etc.) voor de gasprijzen binnen dat bereik.
- Presenteer de resultaten in een tabel.

Matplotlib en Seaborn:

- Herhaal een van de bovenstaande plots (bijvoorbeeld boxplot) met behulp van Matplotlib en Seaborn in plaats van de standaard plotfuncties.
- Vergelijk de esthetiek en mogelijkheden van Matplotlib en Seaborn met die van de standaard plotfuncties.