

ML Principles: Labo/Project 2 - Uitgebreide Data-analyse en Interpretatie

Hassan Haddouchi

Het labo bestaat uit **twee delen** en zal zich spreiden over **twee labo contactmomenten**. Volgende week zal ik klassikaal een live demonstratie geven van mijn voorbeeldoplossing. Niet alle voorbeeldoplossingen worden gedeeld op Digitap. ***Het contactmoment volgende week zal dus de enige kans zijn om directe feedback te krijgen door middel een live demonstratie.***

In de vorige opdracht hebben jullie de nodige Python-libraries geïnstalleerd en eenvoudige operaties uitgevoerd op een dataset.

In deze opdracht gaan we een stap verder en voeren we een uitgebreidere analyse uit op een dataset. De focus ligt niet alleen op **het berekenen van statistieken**, maar ook op **het interpreteren van de gegevens**. Dit is een essentiële stap in machine learning, waarbij we ervoor moeten zorgen dat de dataset die we in een model willen gebruiken, grondig wordt onderzocht.

BELANGRIJK!!! Dit geldt voor alle labo's: maak je code reproduceerbaar en zonder afhankelijkheden (i.e. ik moet de code rechtstreeks kunnen uitvoeren zonder extra bestanden te moeten downloaden of waarbij het pad naar je dataset niet juist is. Zorg daarom dat je dataset zich in dezelfde folder bevindt als je Python bestand. Kijk op Digitap hoe je dit kan doen. Niet-complete inzendingen (bijvoorbeeld door een ontbrekende dataset of door een verkeerd pad naar de dataset) resulteren voor de nodige minpunten. Deze mededeling zal in de volgende opdrachten niet meer staan, maar blijft uiteraard gelden voor alle inzendingen en het examen.

Deel 1 - Eerste inzichten uit een dataset

Vorbereiding

1. **Start VS Code** en maak een nieuw Python-bestand aan.
2. **Download en laad de dataset in** via [deze website](#), zoek de dataset over '**Speed and Stopping Distances of Cars**'.
3. **Lees de dataset in** met behulp van Pandas. Maak de eerste kolom de index van het DataFrame met parameter `index_col=0` in de functie `read_csv()`. Dit komt omdat in je CSV de eerste kolom niet relevant is voor je data-analyse.
4. **Toon de eerste vijf rijen van de dataset** om een eerste idee te krijgen van de structuur.

Je merkt nu dat we in deze dataset te maken hebben met de variabelen tijd en snelheid. We zouden dus een manier moeten kiezen waarin we de snelheid over een ruimtelijke dimensie kunnen uitdrukken.

Analyse en Visualisaties

5. Wanneer je met een dataset wil werken en deze wil gebruiken voor je ML model, is het belangrijk om te weten wat de datatypes zijn van de variabelen. **Controleer de datatypes van de variabelen** ('speed' en 'dist') en geef deze weer. Je kan hiervoor de attribuut `dtypes` gebruiken.

De `dtypes`-attribuut van een pandas series geeft het datatype weer van de gegevens in die kolom. Als beide variabelen als natuurlijke getallen worden behandeld, zullen de datatypes `int` zijn.

```
Datatype van 'speed': int64  
Datatype van 'distance': int64
```

6. **Controleer op ontbrekende data** in de dataset en toon het aantal ontbrekende waarden per kolom. Gebruik hiervoor de functie `isnull()` en de functie `sum()` om het totale aantal ontbrekende waarden te berekenen.

De `isnull()`-functie geeft een DataFrame met booleans terug, waarbij `True` aangeeft dat de waarde ontbreekt. Door vervolgens `sum()` toe te passen, krijg je het totale aantal ontbrekende waarden in de kolom.


Als het gelijk is aan 0, betekent dit dat er geen ontbrekende waarden zijn in de kolom `speed`. Als het aantal groter is dan 0, geeft het aan hoeveel ontbrekende waarden er zijn.

```
Aantal ontbrekende waarden in 'speed': 0`  
Aantal ontbrekende waarden in 'dist': 0`
```

7. **Bepaal de minimum- en maximumwaarden** van beide variabelen. Maak gebruik van de `min()` en `max()` functies van pandas.

```
Minimumwaarde van 'speed': 4`  
Maximumwaarde van 'speed': 25`  
Minimumwaarde van 'dist': 2`  
Maximumwaarde van 'dist': 120`
```

8. **Genereer een histogram voor de variabele 'dist'** en beschrijf in je portfolio kort wat je uit deze visualisatie kunt afleiden.



9. **Maak een correlatiematrix** tussen 'speed' en 'dist'. Toon deze met een heatmap en interpreteer de resultaten: Hoe sterk is de correlatie tussen deze twee variabelen? Gebruik de functie `corr()`. Je kan Seaborn gebruiken voor het visualiseren van de correlatiematrix.

```
plt.figure(figsize=(8,6))
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt=".2f",
linewidths=0.5)
plt.title("Correlatiematrix van de dataset")
plt.show()
```


In dit geval zal je dus Matplotlib gebruiken om de heatmap weer te geven, aangezien Seaborn bovenop Matplotlib werkt.

Een **correlatiematrix** is een tabel waarin de onderlinge relaties tussen numerieke variabelen worden weergegeven. De waarden in de matrix variëren van **-1** tot **1**:


- **Een waarde van 1** betekent een perfecte positieve correlatie: als de ene variabele stijgt, stijgt de andere ook.
- **Een waarde van -1** betekent een perfecte negatieve correlatie: als de ene variabele stijgt, daalt de andere.
- **Een waarde rond 0** betekent dat er weinig tot geen verband is tussen de variabelen.

In deze opdracht wordt de correlatiematrix gebruikt om te onderzoeken hoe sterk '**speed**' en '**dist**' met elkaar gecorreleerd zijn. Dit helpt ons te begrijpen of de snelheid van een voertuig invloed heeft op de remafstand.

Met behulp van een **heatmap** kunnen we deze matrix visueel weergeven, waarbij kleurgradaties aangeven hoe sterk de correlaties zijn. Dit biedt een snelle en intuïtieve manier om patronen in de dataset te herkennen.



10. **Maak een lijndiagram** waarin je 'speed' weergeeft over een ruimtelijke dimensie. Interpreteer wat de trend lijkt te zijn in je portfolio.



Reflectie: beschrijf kort in je portfolio wat je hebt geleerd uit deze dataset. Welke patronen herken je? Wat zou dit kunnen betekenen in een realistische context?

Deel 2 - Uitgebreide analyse en keuzevrijheid in visualisatie

Vorbereiding

1. **Download en laad de dataset over woningprijzen in Boston** in via [deze website](#). De dataset heet 'Housing Values in Suburbs of Boston'.
2. **Lees de dataset in** met Pandas en toon de eerste vijf rijen.
3. **Bekijk de documentatie van de dataset** (klik op de 'DOC' link naast de dataset) en selecteer **minstens vier variabelen** die je relevant vindt om verder te onderzoeken.

Data-analyse en visualisatie

4. **Controleer de datatypes en ontbrekende waarden** voor de vier geselecteerde variabelen.
5. **Bereken de gemiddelde, minimale en maximale waarde** van deze variabelen en geef deze weer in een overzichtelijke tabel.
6. **Maak een correlatiematrix** tussen deze variabelen en visualiseer deze met een heatmap. Welke relaties tussen variabelen vallen je op?
7. **Distributieanalyse van de huizenprijzen:** bereken en visualiseer de verdeling van de huizenprijzen (`medv` - mediane waarde van huizen). Gebruik hiervoor een gepaste histogram en beschrijf in je portfolio kort wat de spreiding van de huizenprijzen aangeeft.
8. **Onderzoek de invloed van de afstand tot het zakencentrum (`dis`) en de criminaliteitsgraad (`crim`) op de huizenprijzen (`medv`).** Maak een scatterplot waarin de afstand (`dis`) wordt afgezet tegen de huizenprijzen en analyseer of verder gelegen huizen duurder of goedkoper zijn. Voeg een tweede

scatterplot toe waarin de criminaliteitsgraad (**crim**) wordt afgezet tegen de huizenprijzen en interpreteer of er een trend zichtbaar is. Licht toe in je portfolio.

9. **Zelfstandige visualisatiekeuze:** kies op basis van je inzichten uit de dataset **een extra visualisatie** die volgens jou nuttig kan zijn. Dit mag een boxplot, scatterplot, barplot of histogram zijn. Motiveer je keuze in je portfolio.

Reflectie: beschrijf in je portfolio wat je uit de analyse van deze dataset hebt geleerd. Welke variabelen blijken het belangrijkste? Wat kunnen de getoonde trends betekenen voor de huizenmarkt?

Verwachtingen en Evaluatie

- Dit projectje dient **gestructureerd en reproduceerbaar** ingediend te worden.
- Code dient **correct** te zijn en **commentaar** te bevatten waar nodig.
- Interpretatie van resultaten is **essentieel**. Enkel technische uitvoering is **niet voldoende**.
- Studenten hebben **vrijheid** om op basis van eigen inzicht zelf een visualisatie te kiezen en te beargumenteren.

Veel succes!