

ML Principles: Labo/Project 2 - Uitgebreide Data-analyse en Interpretatie

Uitbreiding

Hassan Haddouchi

Nu je de dataset hebt geanalyseerd en de verbanden tussen de variabelen hebt onderzocht, gaan we een stap verder om inzicht te krijgen in welke variabelen de beste voorspellers zijn voor de targetvariabele.

Doel van deze uitbreiding

- Je leert dat correlatie een belangrijke eerste stap is in het begrijpen van data en het identificeren van relevante variabelen.
- Je ontdekt dat niet alle verbanden lineair hoeven te zijn en dat transformaties soms nuttig zijn.
- De interpretatie van de resultaten is net zo belangrijk als de berekening zelf.

Opdracht

Identificeer de 3 variabelen met de hoogste absolute correlatie met **medv**.

- Bereken de top 3 sterkst gecorreleerde variabelen (positief of negatief).

Bijvoorbeeld:

```
correlation_matrix = df.corr() # Correlatiematrix berekenen


medv_corr = correlation_matrix['medv'].abs().sort_values(ascending=False) #
Absolute waarden en sorteren

top_3_features = medv_corr.index[1:4] # Eerste waarde is 'medv' zelf, dus we
nemen index 1-3
```

- Geef een korte interpretatie: wat betekent dit in de context van huizenprijzen (portfolio)?


Maak scatterplots van **medv** tegen de 2 meest significante variabelen.

- Gebruik Seaborn's regplot om een regressielijn toe te voegen.
- Voeg titels en labels toe.
- Schrijf kort op wat je observeert in de trends (portfolio).



Onderzoek een mogelijke niet-lineaire relatie

- Kies de variabele met de hoogste niet-lineaire trend in de scatterplots.
- Pas een log-transformatie of kwadratische transformatie toe op deze variabele.
- Maak opnieuw een scatterplot met de getransformeerde variabele en 'medv'.
- Beantwoord de vraag: is de relatie na transformatie duidelijker?



Extra toelichting met betrekking tot bovenstaande concepten:

Regressielijn

Een regressielijn in een scatterplot helpt om de trendlijn tussen twee variabelen te visualiseren. Het geeft een indicatie van hoe sterk en in welke richting de ene variabele samenhangt met de andere.

Het helpt om:

- De richting van de relatie te bepalen (positief of negatief).
- Te zien hoe sterk de punten rond de lijn liggen (hoe minder spreiding, hoe sterker de relatie).
- Mogelijke afwijkingen of patronen te ontdekken die niet lineair zijn.

Als de regressielijn een duidelijke rechte lijn vormt, wijst dit op een lineaire relatie. Als de punten een gebogen of krom patroon vormen, betekent dit dat er mogelijk niet-lineariteit is.

Wat is niet-lineariteit?

Een niet-lineaire relatie betekent dat de relatie tussen twee variabelen geen rechte lijn vormt in een scatterplot. Dit betekent dat de waarde van de ene variabele op een complexere manier verandert naarmate de andere variabele toeneemt of afneemt.

Als de scatterplot een gebogen trend toont, betekent dit dat een lineair model niet de beste manier is om de relatie te beschrijven.

Om niet-lineaire relaties beter te modelleren, kunnen we een transformatie toepassen op een variabele. De twee meest gebruikte methoden zijn:

Log-transformatie ($\log(x)$)

- Gebruikt wanneer een variabele een exponentiële groei of afnemend effect vertoont.
- Vermindert de invloed van extreme waarden (uitschieters).
- Maakt de relatie meer lineair, zodat een regressiemodel beter kan passen.

Kwadratische transformatie (x^2)

- Gebruikt wanneer de relatie U-vormig of omgekeerd U-vormig is.
- Versterkt de verschillen tussen hoge en lage waarden.
- Kan helpen om een betere voorspelling te maken als een variabele een gebogen effect heeft op 'medv'.

Als de punten beter geordend langs een rechte lijn liggen, betekent dit dat de log-transformatie een betere weergave van de relatie geeft.

Veel succes!