

ML Principles: labo 3

Hassan Haddouchi

De naam van deze opdracht is Univariate Analysis. Univariate analyse onderzoekt elke variabele in een dataset afzonderlijk.

We gaan vandaag nog niet elke variabele in een dataset onderzoeken, maar dat zal ons niet weerhouden om al een eerste aanzet naar een univariate analyse te maken.

Zo'n analyse kijkt onder andere naar het bereik van waarden, evenals de centrale tendens van de waarden. Het beschrijft ook patronen op de variabele. Hieronder zal je enkele vragen terugvinden die je alvast kan meenemen in je analyse.

Vorbereiding

Start VS Code en maak een nieuw Python file aan.

Opdracht


Zoek op [deze website](#) naar de dataset met bevolkingscijfers van de staten in Australië voor 1917, 1927, ..., 1997. De packagenaam van de dataset is DAAG (item austpop). Zoek in de lijst op [austpop](#).

1. Download de dataset
2. Lees de dataset in door middel van Pandas. Dit zorgt ervoor dat je dataset nu een tabel (DataFrame) in Python is.
3. Geef nu een tabel weer van je dataset. Zorg voor een titel en de juiste benamingen voor de assen.

Tabel van de dataset:

	rownames	year	NSW	Vic	Qld	SA	WA	Tas	NT	ACT	Aust
0	1	1917	1904	1409	683	440	306	193	5	3	4941
1	2	1927	2402	1727	873	565	392	211	4	8	6182
2	3	1937	2693	1853	993	589	457	233	6	11	6836
3	4	1947	2985	2055	1106	646	502	257	11	17	7579
4	5	1957	3625	2656	1413	873	688	326	21	38	9640


4. Genereer 2 plots over de bevolkingsdata in SA en ACT. Analyseer de gegevens, wat zijn de verschillen? wat kan je concluderen?



5. Wat is het datatype van de data in uw plot? *Gebruik hiervoor de attribuut `{dtype}`*

```
```{python}
data_type_sa = df['SA'].dtype
```

6. Genereer een plot met de verdeling van de bevolkingsdata in ACT. Kijk naar de verdeling in uw plot rond gegevens van de staat ACT. Volgt dit volgens jou de normale verdeling? *Normaal verdeelde data heeft de volgende eigenschappen: observaties rond het gemiddelde zijn het waarschijnlijkst. Hoe verder waarden van het gemiddelde af liggen, hoe onwaarschijnlijker het is deze waarden te observeren.*



7. Zijn er limieten waartussen de waarden zich bevinden in uw plot? Zo ja, welke?

Voorbeeld:


```
lower_limit_act = df['ACT'].min()
```

8. Wat zijn de modi in beide figuren? Een *modus* is de waarde die het meeste voorkomt.

Voorbeeld:

```
mode_sa = df['SA'].mode().values
```

9. Bereken het gemiddelde van de bevolkingsdata voor elke staat over alle jaren. Plot vervolgens de gemiddelde bevolking per staat.



10. Bereken de jaarlijkse groeipercentages van de bevolking voor elke staat. Plot vervolgens de jaarlijkse groeipercentages in lijngrafieken.

