

ML Principles: labo 3 deel 2

Hassan Haddouchi

Labo: data voorbereiden en representeren voor AI-Modellen

Doel:

Dit labo richt zich op **het structureren, representeren en voorbereiden van data** in een geschikt formaat voor AI-modellen. We gaan werken met **verschillende datatypes, categorische en numerieke data, en feature-representatie**.

Wat zal je leren?

- ✓ **Werken met datatypes en datastructuren** (zoals besproken in hoofdstuk 3).
 - ✓ **Focussen op representatie van data in AI-modellen**, zonder in te gaan op exploratieve analyses.
 - ✓ **Categorische en numerieke data behandelen**, een kernonderdeel van hoofdstuk 3.
-

Dataset

We gebruiken de **Titanic dataset** van **Seaborn**, die passagiersgegevens van de Titanic bevat en verschillende **numerieke en categorische variabelen** omvat.

Vorbereiding:

Installeer en importeer Seaborn

Laad de Titanic dataset in met `sns.load_dataset('titanic')`

Deel 1: datatypes en structuren in AI

1. **Lees de Titanic dataset in met Pandas en toon de eerste 5 rijen.**
2. **Controleer de datatypes van de kolommen** en bepaal welke variabelen numeriek en welke categorisch zijn.
Naast het attribuut `dtypes` dat je kan gebruiken op je dataframe, kan je ook gebruik maken van de functie `select_dtypes()` om numerieke variabelen te verzamelen en te printen. Hetzelfde doe je dan voor het andere type.

Een andere aanpak is (gebruikt **Pandas**):

```
numerical_vars = [col for col in df.columns if
pd.api.types.is_numeric_dtype(df[col])]
print(numerical_vars)
```

3. **Converteer een categorische variabele naar numerieke representatie** met behulp van **Label Encoding** of **One-Hot Encoding**. Print de variabele en bekijk de aanpassingen.

4. Beantwoord de volgende vragen in de reflectie van je portfolio:

- Welke variabele(n) kunnen **ordinaal** worden beschouwd?
- Welke variabelen zijn **nominaal** en moeten anders worden behandeld?

Tips:

- Voor Label Encoding heb je preprocessing uit de library **sklearn** nodig. Dit moet je bovenaan je code importeren:

```
from sklearn.preprocessing import LabelEncoder
```

- Je kan de functie **fit_transform** gebruiken.

Reflectie portfolio: waarom is het belangrijk om het juiste datatype te kiezen in AI-toepassingen?

Deel 2: omgaan met Categorical Data in AI

5. Voer een feature-representatie uit op de kolommen 'sex' en 'embark_town'.

- Gebruik **One-Hot Encoding** voor 'embark_town'.
- Gebruik **Label Encoding** voor 'sex'.

6. Vergelijk de impact van beide methodes:

- Wat is het verschil tussen de twee?
- Welke methode is het meest geschikt en waarom?

Tip: gebruik **pd.get_dummies()** voor One-Hot Encoding en **LabelEncoder()** uit **sklearn.preprocessing** voor Label Encoding.

Voorbeeld:

```
df = pd.get_dummies(df, columns=['embark_town'], drop_first=True)
```

Deel 3: data cleaning en voorbereiding

7. Controleer op ontbrekende waarden en beslis wat de beste aanpak is.

- Imputeren met de gemiddelde waarde
- Verwijderen van records
- Vullen met de meest voorkomende waarde

8. Voer de gekozen strategie uit en beargumenteer in je portfolio waarom je deze keuze hebt gemaakt.

9. Controleer de dataset opnieuw: zijn er nog ontbrekende waarden?

Tips:

- Gebruik `df.isnull().sum()` om ontbrekende waarden te controleren.
- Je kan `fill.na()` gebruiken. Maar onderzoek eerst wat deze functie precies doet.

Extra: correlatiematrix van numerieke variabelen

10. Maak een correlatiematrix van de numerieke variabelen en visualiseer deze met een heatmap.
11. Welke variabelen vertonen de sterkste correlaties? Wat zou dit kunnen betekenen in de context van de Titanic?

Gebruik Seaborn's `sns.heatmap()` om de correlatiematrix visueel weer te geven.

Reflectie en evaluatie (Portfolio)

- Wat heb je geleerd over hoe data correct moet worden **voorgeformatteerd** voordat het wordt gebruikt in AI-modellen?
- Welke technieken waren het meest zinvol voor **categorische variabelen**?
- Waarom is een **juiste datarepresentatie** cruciaal voor machine learning?

Voorbeeld-output (behalve de correlatiematrix)

Eerste 5 rijen van de dataset:

	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	who	adult_male	deck	embark_town	alive	alone
0	0	3	male	22.0	1	0	7.2500	S	Third	man	True	NaN	Southampton	no	False
1	1	1	female	38.0	1	0	71.2833	C	First	woman	False	C	Cherbourg	yes	False
2	1	3	female	26.0	0	0	7.9250	S	Third	woman	False	NaN	Southampton	yes	True
3	1	1	female	35.0	1	0	53.1000	S	First	woman	False	C	Southampton	yes	False
4	0	3	male	35.0	0	0	8.0500	S	Third	man	True	NaN	Southampton	no	True

Datatypes van de kolommen:

```
survived      int64
pclass        int64
sex           object
age           float64
sibsp         int64
parch         int64
fare          float64
embarked      object
class         category
who           object
adult_male    bool
deck          category
embark_town   object
alive         object
alone         bool
dtype: object
```

Numerieke variabelen: ['survived', 'pclass', 'age', 'sibsp', 'parch', 'fare']

Categorische variabelen: ['sex', 'embarked', 'class', 'who', 'deck', 'embark_town', 'alive']

Voorbeeld van de 'class' variabele voor en na encoding:

	class	class_encoded
0	Third	2
1	First	0
2	Third	2
3	First	0
4	Third	2

Aantal ontbrekende waarden per kolom:

survived	0
pclass	0
sex	0
age	177
sibsp	0
parch	0
fare	0
embarked	2
class	0
who	0
adult_male	0
deck	688
alive	0
alone	0
class_encoded	0
embark_town_Queenstown	0
embark_town_Southampton	0
dtype: int64	

Aantal ontbrekende waarden na imputatie:

survived	0
pclass	0
sex	0
age	0
sibsp	0
parch	0
fare	0
embarked	2
class	0
who	0
adult_male	0
deck	688
alive	0
alone	0
class_encoded	0
embark_town_Queenstown	0
embark_town_Southampton	0
dtype: int64	