

ML Principles: labo 4

Hassan Haddouchi

Inleiding en doel van de opdracht:

Let op: het is belangrijk om de uitleg die ik voorzie in de opdrachten te lezen om het doel van elke opdracht goed te begrijpen. Neem daarom de tijd om alle toelichtingen en stappen te overlopen voor je aan de opdracht begint.

Dit project omvat (bijna) alle aspecten die we tot nu toe hebben gezien in het opleidingsonderdeel ML Principles. We zullen beginnen bij een probleemstelling en de project-lifecycle van een ML project doorlopen tot data-manipulatie.

Het doel van deze opdracht is om de concepten die we in de vorige lessen en labo's hebben gezien, toe te passen in een algehele probleemstelling. Dit omvat o.a. het begrijpen van de probleemstelling, het vinden van de juiste dataset

Vorbereiding:

Start VS Code en maak een nieuw Python file aan.

Opdracht

Vandaag zullen we met een nieuwe dataset werken. Ditmaal gaat de dataset over het vertrouwen tegenover de Belgische politie.

Probleemstelling:

Stel dat we van de Belgische overheid de opdracht hebben gekregen om het vertrouwen in de Belgische politie te onderzoeken. We worden voorzien van een dataset waarbij het onze taak is om de overheid te informeren over de deze data, hoe deze data eruitzien, wat de vorm is van deze data, of het betrouwbare data is, of deze dataset in de toekomst kan worden gebruikt in een ML programma, enzovoort.

Zoek op [deze website](#) naar de juiste dataset met de naam 'Trust in the Police in Belgium'.

1. **Observeer** op de website hoeveel rijen deze dataset heeft, alsook hoeveel kolommen (variabelen). Voor een beter begrip raad ik aan om de documentatie van de dataset te bekijken.
2. **Inladen dataset:** download de dataset en lees deze in in uw Python bestand door de gebruikelijke manier. Als je Pandas gebruikt bij het inlezen van de data, wordt je data meteen naar een DataFrame omgezet, wat handig is om straks bewerkingen uit te voeren op je data.
3. **Verken de dataset:**
 - Geef een samenvatting weer van de dataset met de eerste en laatste set rijen.
 - Geef weer hoeveel rijen en kolommen (variabelen) de dataset bevat.

Samenvatting van de dataset:

	rownames	essround	edition	idno	cntry	trstplc	agea	female	eduyrs	hincfel	plcpvcr
0	1	5	3.4	100102	BE	7.0	22	0	15.0	2.0	5.0
1	2	5	3.4	100106	BE	4.0	43	0	15.0	3.0	5.0
2	3	5	3.4	100202	BE	10.0	19	1	13.0	3.0	5.0
3	4	5	3.4	100204	BE	5.0	23	1	15.0	1.0	4.0
4	5	5	3.4	100209	BE	8.0	58	1	15.0	1.0	8.0
	rownames	essround	edition	idno	cntry	trstplc	agea	female	eduyrs	hincfel	plcpvcr
1699	1700	5	3.4	136302	BE	8.0	36	0	15.0	2.0	7.0
1700	1701	5	3.4	136303	BE	8.0	62	0	8.0	2.0	2.0
1701	1702	5	3.4	136304	BE	7.0	82	0	10.0	1.0	7.0
1702	1703	5	3.4	136307	BE	6.0	49	1	16.0	2.0	5.0
1703	1704	5	3.4	136309	BE	4.0	70	1	6.0	2.0	3.0

Aantal rijen en kolommen:

(1704, 11)

- Voer nu de DIPKEVER analyse uit op elke variabele van de dataset. Kijk in de cursus naar de criteria van deze analyse.

Controleer hierbij onder andere op ontbrekende waarden, duplicaten, het type van de variabele, hoe de dataset in het algemeen en de variabele specifiek tot stand is gekomen, of het voor de overheid verantwoord is om de variabele en de instanties te gebruiken in een ML proces, of de variabele of een bepaalde instantie de privacy van één of meerdere individuen schendt, of de variabele voorradig is, of het ethisch verantwoord is om de variabele te gebruiken, kortom, de DIPKEVER analyse.

Het is dus belangrijk om voor ELKE variabele de DIPKEVER criteria te overlopen!

```

#   Column      Non-Null Count  Dtype
---  -
0   rownames    1704 non-null    int64
1   essround     1704 non-null    int64
2   edition      1704 non-null    float64
3   idno         1704 non-null    int64
4   cntry        1704 non-null    object
5   trstplc      1701 non-null    float64
6   agea         1704 non-null    int64
7   female       1704 non-null    int64
8   eduyrs       1668 non-null    float64
9   hincfel      1697 non-null    float64
10  plcpvcr      1690 non-null    float64
dtypes: float64(5), int64(5), object(1)

```

Ontbrekende waarden behandelen:

```

rownames    0
essround     0
edition      0
idno         0
cntry        0
trstplc      3
agea         0
female       0
eduyrs       36
hincfel      7
plcpvcr      14


```

4. Data cleaning en voorbereiding


- Je hebt reeds gecontroleerd op ontbrekende waarden in de instanties. Als er ontbrekende waarden zijn, is het belangrijk om ze nu te behandelen. Doorgaans zal je twee opties hebben:
 - imputeren: bijvoorbeeld de vorige of volgende waarde invullen, maximum of minimum waarde, het voorspellen van de ontbrekende waarde, gemiddelde waarde, ... Natuurlijk dien je hier heel bewust mee om te gaan. De meest voorkomende techniek is de ontbrekende waarde vervangen door het gemiddelde van de variabele.
 - verwijderen: de instantie die de ontbrekende waarde bevat verwijderen.
- Dubbele rijen (duplicaten) of kolommen mag je ook verwijderen.
- Indien de dataset gegevens bevat die niet relevant zijn voor onze probleemstelling, mag je de dataset transformeren om alleen relevante gegevens voor de analyse te behouden.

5. Visualisatie van de dataset voor de analyse


- Visualiseer nu de numerieke waarden van de variabele *trstplc* om het vertrouwen in de Belgische politie te visualiseren. Voorzie uw visualisatie van de juiste termen zodat deze makkelijk leesbaar is. In de documentatie kan je meer terugvinden over hoe je de waarden van deze variabele kan interpreteren. Kies zelf het type van uw visualisatie, bijvoorbeeld een staafdiagram, lijndiagram of een scatterplot.



- Doe hetzelfde voor de variabele *agea*



- Breng nu beide variabelen samen in één histogram of plot, zodat we per leeftijd kunnen lezen wat het vertrouwen is in de Belgische politie. Maak gebruik van een lijndiagram of scatterplot.



Elke punt op de plot vertegenwoordigt een respondent in de dataset, waarbij de x-as de leeftijd van de respondenten weergeeft en de y-as het vertrouwen in de politi op een schaal.

Als de punten een duidelijke opwaartse of neerwaartse trend volgen, kunnen we concluderen dat er mogelijk een correlatie bestaat tussen leeftijd en vertrouwen. Een opwaartse trend zou suggereren dat oudere respondenten over het algemeen meer vertrouwen hebben in de politie dan jongere respondenten, terwijl een neerwaartse trend het tegenovergestelde zou impliceren.

6. Analyse

- Om onze opdrachtgever ook een beeld te geven van de respondenten en de resultaten in de dataset, bereken je ook het gemiddelde van de volgende variabelen:
 - `agea` om de gemiddelde leeftijd te weten van de respondenten
 - `trstplc` om de gemiddelde numerieke waarde op een schaal van 11 te weten met betrekking tot het vertrouwen in de politie.

Gemiddelde leeftijd van de respondenten: 46

Gemiddeld vertrouwen in de Belgische politie: 6

- `plcpvcr` idem `trstplc`
- Zijn er meer mannelijke of vrouwelijke deelnemers?
- Zoek uit of er correlaties bestaan tussen variabelen. Gebruik hiervoor de `corr()`-functie. Mogelijk zal je als parameter `numeric_only=True` moeten meegeven om de correlatie enkel op numerieke waarden toe te passen.

Correlaties tussen variabelen:

	rownames	essround	edition	idno	trstplc	agea	female	eduyrs	hincfel	plcpvcr
rownames	1.000000	NaN	NaN	0.999819	-0.012672	0.004177	-0.009028	-0.017150	0.038529	0.021527
essround	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
edition	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
idno	0.999819	NaN	NaN	1.000000	-0.012350	0.003065	-0.010251	-0.015645	0.038876	0.021993
trstplc	-0.012672	NaN	NaN	-0.012350	1.000000	-0.067071	-0.000109	0.100009	-0.134855	0.384667
agea	0.004177	NaN	NaN	0.003065	-0.067071	1.000000	0.000666	-0.208120	0.130965	0.064854
female	-0.009028	NaN	NaN	-0.010251	-0.000109	0.000666	1.000000	0.002944	0.107977	0.017967
eduyrs	-0.017150	NaN	NaN	-0.015645	0.100009	-0.208120	0.002944	1.000000	-0.168786	-0.056377
hincfel	0.038529	NaN	NaN	0.038876	0.134855	0.130965	0.107977	-0.168786	1.000000	-0.005579
plcpvcr	0.021527	NaN	NaN	0.021993	0.384667	0.064854	0.017967	-0.056377	-0.005579	1.000000

Probeer uw correlatietabel te interpreteren.

Een correlatietabel toont de correlatiecoëfficiënten tussen verschillende variabelen in de dataset. Deze coëfficiënten variëren tussen -1 en 1, waarbij:

1 een perfecte positieve correlatie aangeeft (als de ene variabele stijgt, stijgt de andere variabele ook), -1 een perfecte negatieve correlatie aangeeft (als de ene variabele stijgt, daalt de andere variabele), en 0 aangeeft dat er geen correlatie is tussen de variabelen.

Een positieve correlatiecoëfficiënt (dichter bij 1) geeft aan dat de variabelen positief samenhangen, terwijl een negatieve correlatiecoëfficiënt (dichter bij -1) aangeeft dat de variabelen negatief samenhangen.

7. Rapportering en reflectie Beschrijf in uw portfolio uw bevindingen.

Veel succes!