

ML Principles: labo 5

Hassan Haddouchi

Inleiding en doel van de opdracht:

Het doel van deze opdracht is een eerste kennismaking met machinaal leren, i.e. een model maken, het model trainen en een voorspelling maken.

We zullen een lineair regressiemodel maken om een mean square error te berekenen.

Vorbereiding:

Start VS Code en open een nieuw Python bestand.

Opdracht

Een voorspelling maken met lineaire regressie op basis van een dataset.

Onderaan dit document vinden jullie wat extra lectuur terug om nieuwe concepten beter te begrijpen.

Probleemstelling:

Je bent belast met de taak om een eenvoudig machine learning-model te ontwikkelen dat een lineair regressie model maakt om een voorspelling te geven. De taak is om de Boston Housing dataset te gebruiken om de mediane huisprijs te voorspellen op basis van het gemiddelde aantal kamers per woning.

1. **Dataset inladen:** Laad de Boston Housing dataset in. Veel van zulke datasets kan je vanuit de scikit-learn bibliotheek in Python inladen. Dat doe je zo:

```
from sklearn.datasets import load_boston
boston = load_boston()
```

Maar voor de Boston Housing dataset is dat niet meer het geval. Daarom zullen we de dataset rechtstreeks van de UCI Machine Learning Repository downloaden:

```
from sklearn.datasets import fetch_openml
boston = fetch_openml(data_id=531)
```

Je code tot nu zou er zo moeten uitzien:

```
# Stap 1: Dataset inladen
import pandas as pd
from sklearn.datasets import fetch_openml

# Laad de dataset in vanuit de UCI Machine Learning Repository
boston = fetch_openml(data_id=531)
```

```
# Converteer de dataset naar een DataFrame
df = pd.DataFrame(data=boston.data, columns=boston.feature_names)
```

2. Verken de dataset:

- Geef een samenvatting van de dataset weer, inclusief informatie over het aantal rijen en kolommen, en enkele voorbeeldrijen.

Samenvatting van de dataset:

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296.0	15.3	396.90	4.98	24.0
1	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242.0	17.8	396.90	9.14	21.6
2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242.0	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222.0	18.7	396.90	5.33	36.2

- Controleer of er ontbrekende waarden zijn in de dataset en handel deze af indien nodig.

Ontbrekende waarden in de dataset:

```
CRIM      0
ZN        0
INDUS     0
CHAS      0
NOX       0
RM        0
AGE       0
DIS       0
RAD       0
TAX       0
PTRATIO   0
B         0
LSTAT     0
MEDV      0
dtype: int64
```

- Selecteer invoer- en uitvoervariabelen:** Selecteer de 'RM' (gemiddeld aantal kamers per woning) als invoervariabele en de 'MEDV' (median value of owner-occupied homes) als uitvoervariabele voor het model.

BELANGRIJK!!: sommige studenten krijgen de target variabele 'MEDV' niet te zien. In dat geval raad ik aan om het boston.csv bestand te downloaden van de website met de datasets.

- Split de dataset:** Split de dataset in een trainingsset (80%) en een testset (20%) met behulp van de `train_test_split` functie van scikit-learn.
- Model bouwen:** Bouw een eenvoudig lineair regressiemodel met behulp van de `LinearRegression` klasse van scikit-learn.
- Model trainen:** Train het lineaire regressiemodel op de trainingsset met behulp van de `fit` methode.
- Voorspelling maken:** Maak voorspellingen op de testset met behulp van de `predict` methode.

7. **Evalueren van het model:** Bereken de Mean Squared Error (MSE) tussen de werkelijke waarden en de voorspelde waarden met behulp van de `mean_squared_error` functie van `scikit-learn`.

Mean Squared Error (MSE): 46.144775347317264

Coëfficiënten van het model:

Coefficient

RM 9.348301

□

8. **Analyseer de resultaten:** Analyseer de verkregen MSE-waarde en probeer deze te interpreteren. Bespreek ook mogelijke verbeteringen voor het model.

Extra uitleg

Wat is lineaire regressie? Lineaire regressie is een statistische methode waarmee we de relatie tussen een of meer onafhankelijke variabelen (invoervariabelen) en een afhankelijke variabele (uitvoervariabele) onderzoeken. In dit geval is het doel om de invloed van het gemiddeld aantal kamers per woning (invoervariabele) op de mediane huisprijs (uitvoervariabele) te begrijpen.

Kort gezegd is lineaire regressie is een manier om te begrijpen hoe twee dingen samenhangen en om te voorspellen wat er zou kunnen gebeuren op basis van die relatie. Het is als het trekken van een rechte lijn door punten op een grafiek om te helpen voorspellen wat er gebeurt als je een nieuwe situatie tegenkomt.

Wat is de Mean Squared Error (MSE)? De Mean Squared Error (MSE) geeft aan hoe ver de voorspelde waarden van het model afwijken van de werkelijke waarden. In dit geval is de MSE ongeveer 46.144.

Een lage MSE geeft aan dat het model goede voorspellingen maakt, terwijl een hoge MSE aangeeft dat het model slechte voorspellingen maakt.

Wat stelt de coëfficiënt voor? De coëfficiënten van het model geven de invloed weer van elke variabele op de voorspelde waarde. Een positieve coëfficiënt betekent dat een toename in die variabele gepaard gaat met een toename in de voorspelde waarde, terwijl een negatieve coëfficiënt betekent dat een toename in die variabele gepaard gaat met een afname in de voorspelde waarde.