

ML Principles: labo 6

Hassan Haddouchi

Inleiding en doel van de opdracht:

Het doel van deze opdracht is een eerste kennismaking met machinaal leren, i.e. een model maken, het model trainen en een voorspelling maken.

Werk verder op de code van labo 4 dat je vorige week hebt ingediend.

Vorbereiding:

Start VS Code en open je oplossing van labo 4. Een alternatief kan zijn om de modeloplossing op Digitap te gebruiken als startpunt voor deze opdracht.

Opdracht

In labo 4 heb je de data gecontroleerd aan de hand van DIPKEVER, de data voorbereid en de nodige observaties en visualisaties uitgevoerd om een aantal besluiten te nemen over de dataset. Nu gaan we op basis van die analyse een model maken en voorspellen.

Probleemstelling:

Je bent belast met de taak om een eenvoudig machine learning-model te ontwikkelen dat het vertrouwen in de Belgische politie voorspelt op basis van gegevens uit de dataset.

We zullen gebruikmaken van een lineaire regressiemodel.

1. Data voorbereiden:

- Om machinaal te leren op data, dient uw data geen NaN-waarden te bevatten. De variabele *trstplc* bevat NaN waarden.

Gebruik de functie *dropna* om de rijen met deze waarden te verwijderen:

```
data.dropna(subset=['trstplc'], inplace=True)
```

- Ook om machinaal te leren op data, dient uw data geen ontbrekende waarden te bevatten. De dataset rond het vertrouwen in de Belgische politie bevat wel ontbrekende waarden.

Definieer een pipeline met een imputer en het lineaire regressiemodel:

```
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
pipeline = Pipeline([
    ('imputer', SimpleImputer(strategy='mean')), # vervang ontbrekende waarden
    door het gemiddelde van de kolom
```

```
( 'regressor', LinearRegression()) # lineaire regressie model  
])
```

2. **Selecteer relevante variabelen:** In dit geval lijken de variabelen *agea*, *female*, *hincfel*, *plcpvcr* en *trstplc* relevant voor deze probleemstelling. Steek deze variabelen in een array **selected_features**

3. **Splits de dataset:**

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,  
random_state=42)
```

4. **Train het model op de mean_squared_error en evalueer het model**

5. **Analyse:** dit is hoe je de resultaten van je code kan interpreteren.

Het resultaat van de Mean Squared Error (MSE) geeft aan hoe ver de voorspelde waarden van het model afwijken van de werkelijke waarden. In dit geval is de MSE ongeveer 3.122. Een lage MSE geeft aan dat het model goede voorspellingen maakt, terwijl een hoge MSE aangeeft dat het model slechte voorspellingen maakt.

De coëfficiënten van het model geven de invloed weer van elke variabele op de voorspelde waarde. Een positieve coëfficiënt betekent dat een toename in die variabele gepaard gaat met een toename in de voorspelde waarde, terwijl een negatieve coëfficiënt betekent dat een toename in die variabele gepaard gaat met een afname in de voorspelde waarde.

In dit specifieke geval zien we dat de variabele 'agea' een negatieve coëfficiënt heeft, wat betekent dat een hogere leeftijd geassocieerd is met een lagere voorspelde waarde van het vertrouwen in de politie. De variabele 'female' heeft ook een negatieve coëfficiënt, wat suggereert dat vrouwelijke respondenten gemiddeld een lager vertrouwen hebben dan mannelijke respondenten. De variabele 'hincfel' heeft de grootste negatieve invloed op het model, wat betekent dat respondenten die aangeven dat ze het moeilijk hebben met hun huidige inkomen gemiddeld een veel lager vertrouwen hebben in de politie. Aan de andere kant heeft de variabele 'plcpvcr' een positieve invloed, wat aangeeft dat een hogere waardering voor het vermogen van de politie om misdaden te voorkomen, gepaard gaat met een hoger vertrouwen in de politie.