

ML Principles: Labo 8 - Uitgebreide Data-analyse en Interpretatie

Hassan Haddouchi

In de vorige opdracht hebben jullie de nodige Python-libraries geïnstalleerd en eenvoudige operaties uitgevoerd op een dataset.

In deze opdracht gaan we een stap verder en voeren we een uitgebreidere analyse uit op een dataset. De focus ligt niet alleen op **het berekenen van statistieken**, maar ook op **het interpreteren van de gegevens**. Dit is een essentiële stap in machine learning, waarbij we ervoor moeten zorgen dat de dataset die we in een model willen gebruiken, grondig wordt onderzocht.

Deel 1 - Data-exploratie en eerste inzichten

Vorbereiding

1. **Start VS Code** en maak een nieuw Python-bestand aan.
2. **Download en laad de dataset in** via [deze website](#), zoek de dataset over '**Speed and Stopping Distances of Cars**'.
3. **Lees de dataset in** met behulp van Pandas.
4. **Toon de eerste vijf rijen van de dataset** om een eerste idee te krijgen van de structuur.

Analyse en Visualisaties

5. **Controleer de datatypes van de variabelen** ('speed' en 'dist') en geef deze weer.
6. **Controleer op ontbrekende data** in de dataset en toon het aantal ontbrekende waarden per kolom.
7. **Bepaal de minimum- en maximumwaarden** van beide variabelen.
8. **Genereer een histogram voor de variabele 'dist'** en beschrijf kort wat je uit deze visualisatie kunt afleiden.
9. **Maak een correlatiematrix** tussen 'speed' en 'dist'. Toon deze met een heatmap en interpreteer de resultaten: Hoe sterk is de correlatie tussen deze twee variabelen?
10. **Maak een lijndiagram** waarin je 'speed' weergeeft over een ruimtelijke dimensie. Interpreteer wat de trend lijkt te zijn.

Reflectie: Beschrijf kort in je portfolio wat je hebt geleerd uit deze dataset. Welke patronen herken je? Wat zou dit kunnen betekenen in een realistische context?

Deel 2 - Uitgebreide analyse en keuzevrijheid in visualisatie

Vorbereiding

1. **Download en laad de dataset over woningprijzen in Boston** in via [deze website](#). De dataset heet '**Housing Values in Suburbs of Boston**'.
2. **Lees de dataset in** met Pandas en toon de eerste vijf rijen.
3. **Bekijk de documentatie van de dataset** (klik op de '**DOC**' link naast de dataset) en selecteer **minstens vier variabelen** die je relevant vindt om verder te onderzoeken.

Data-analyse en Visualisatie

4. **Controleer de datatypes en ontbrekende waarden** voor de vier geselecteerde variabelen.
5. **Bereken de gemiddelde, minimale en maximale waarde** van deze variabelen en geef deze weer in een overzichtelijke tabel.
6. **Maak een correlatiematrix** tussen deze variabelen en visualiseer deze met een heatmap. Welke relaties tussen variabelen vallen je op?
7. **Tijdreeksanalyse:** Converteer de 'year'-kolom naar een datetime-formaat en maak een tijdreeksplot van de gasprijzen over de jaren.
8. **Distributie van jaarlijkse veranderingen:** Bereken de jaarlijkse veranderingen in gasprijzen en visualiseer deze met een histogram. Wat valt op?
9. **Zelfstandige visualisatiekeuze:** Kies op basis van je inzichten uit de dataset **een extra visualisatie** die volgens jou nuttig kan zijn. Dit mag een boxplot, scatterplot, barplot of histogram zijn. Motiveer je keuze in de commentaar van je code.

Reflectie: Beschrijf in je portfolio wat je uit de analyse van deze dataset hebt geleerd. Welke variabelen blijken het belangrijkste? Wat kunnen de getoonde trends betekenen voor de huizenmarkt?

Verwachtingen en Evaluatie

- Dit labo dient **gestructureerd en reproduceerbaar** ingediend te worden.
 - Code dient **correct** te zijn en **commentaar** te bevatten waar nodig.
 - Interpretatie van resultaten is **essentieel**. Enkel technische uitvoering is **niet voldoende**.
 - Studenten hebben **vrijheid** om zelf een visualisatie te kiezen en te beargumenteren.
-

Deel 3 - Modelvalidatie met Cross-Validation (Nieuwe Dataset)

In dit labo werken jullie met een **andere dataset naar keuze** (niet Iris en niet Boston). Het doel is om **nieuwe inzichten** te verkrijgen én tegelijk te leren hoe je modellen **betrouwbaar evalueert met cross-validation**.

Datasetkeuze

Kies één dataset uit een van de volgende bronnen:

- Kaggle (zoek naar een eenvoudige dataset met max. 10 kolommen)
- UCI Machine Learning Repository
- `seaborn.load_dataset()` (maar NIET 'iris')

Voorwaarden:

- Minstens 1 target variabele
 - Minstens 3 features
 - Beperkt aantal ontbrekende waarden
-

Stap 1 - Verkenning (kort en doelgericht)

1. Toon de eerste rijen van de dataset

2. Controleer datatypes en ontbrekende waarden
3. Kies **minstens 3 features + 1 target**
4. Motiveer kort je keuze in commentaar

➡ Focus: geen uitgebreide EDA zoals vorige labo

Stap 2 - Probleemformulering

Bepaal:

- Is dit een **classificatie** of **regressieprobleem**?
- Wat wil je model voorspellen?

Schrijf dit expliciet uit in commentaar.

Stap 3 - Voorbereiding data

1. Splits in **X (features)** en **y (target)**
 2. Voer **minimale preprocessing** uit:
 - Encoding indien nodig
 - Schalen indien relevant
-

Stap 4 - Model + Cross-Validation

1. Kies een passend model:
 - Classificatie → bv. Logistic Regression, KNN
 - Regressie → bv. Linear Regression
 2. Gebruik **k-fold cross-validation (k=5)**
 3. Gebruik `cross_val_score`
 4. Toon:
 - Scores per fold
 - Gemiddelde score
 - Standaardafwijking
-

Stap 5 - Metrieken

Gebruik afhankelijk van je probleem:

Classificatie:

- Accuracy
- F1-score

Regressie:

- R^2 score
- Mean Squared Error

→ Toon minstens **2 metriekwaarden** en vergelijk ze

Stap 6 - Interpretatie

Beantwoord in max. 7 zinnen:

- Wat betekent de gemiddelde score?
 - Is de spreiding groot of klein? Wat zegt dat?
 - Welke metriek vind je het meest relevant en waarom?
 - Wat zou je verbeteren aan je model?
-

Verwachtingen

- Juiste toepassing van cross-validation
- Correcte keuze van metriek
- Inzicht in resultaten (geen oppervlakkige beschrijving)
- Eigen dataset correct verwerkt

Veel succes!